Cechy sygnału audio w dziedzinie czasu

Dominik Zieliński, Mateusz Stawicki

2 kwietnia 2026

Repozytorium: `https://github.com/xxxDKGxxx/JucerSoundAnalysis`

Spis treści

1 Wstęp **4**

2 Opis aplikacji **5**

2.1 Cel i przeznaczenie 5

2.2 Technologie i środowisko 5

2.3 Interfejs użytkownika 6

3 Opis metod **8**

3.1 Wczytywanie i reprezentacja sygnału 8

3.2 Analiza ramkowa 8

3.3 Parametry ramek w dziedzinie czasu 8

Volume – głośność 9

STE – Short Time Energy 10

ZCR – Zero Crossing Rate 10

SR – Silent Ratio / detekcja ciszy 10

Częstotliwość tonu podstawowego F_0 10

3.4 Detekcja ciszy 12

Eksperymentalne wyznaczanie progów 12

3.5 Określanie fragmentów dźwięcznych i bezdźwięcznych 14

Eksperymentalne wyznaczenie progów 14

3.6 Crest Factor – współczynnik szczytu (własny parametr) 15

3.7 Analiza na poziomie klipu 17

3.8 Parametry klipów w dziedzinie czasu 17

VSTD – Standard Deviation normalized by the maximum volume 17

VDR – Volume Dynamic Range 18

VU – Volume Undulation 18

LSTER – Low Short Time Energy Ratio 18

Energy Entropy – entropia energii 18

ZSTD – Standard Deviation of the ZCR 19

HZCRR – High Zero Crossing Rate Ratio 19

3.9 Klasyfikacja klipów mowa/muzyka 19

Klasyfikacja mowy 19

Klasyfikacja muzyki 20

4 Wnioski **27**

4.1 Napotkane problemy 27

4.2 Ocena działania metod 27

4.3 Wpływ parametrów 28

4.4 Możliwe usprawnienia 28

5 Podsumowanie **28**

1 Wstęp

Celem projektu było opracowanie aplikacji okienkowej przeznaczonej do podstawowej analizy sygnału audio w dziedzinie czasu. Program umożliwia wczytywanie plików w formacie `.wav`, wizualizację przebiegu czasowego sygnału oraz wyznaczanie wybranych parametrów opisujących sygnał na poziomie pojedynczych ramek, jak i bazujące na nich parametry na poziomie klipu.

W ramach projektu przygotowano aplikację o interfejsie graficznym, która umożliwia użytkownikowi wygodne przeprowadzenie analizy oraz obserwację wyników. Nacisk położono zarówno na poprawność obliczeń, jak i na czytelną prezentację rezultatów w postaci wykresów oraz wartości liczbowych.

2 Opis aplikacji

2.1 Cel i przeznaczenie

Opracowana aplikacja służy do analizy sygnałów audio zapisanych w plikach `.wav`. Głównym zadaniem programu jest przedstawienie przebiegu czasowego sygnału oraz wyznaczenie cech opisujących jego lokalne własności w kolejnych ramkach i klipach audio.

Typowy scenariusz użycia programu wygląda następująco:

1. użytkownik uruchamia aplikację,
2. wczytuje plik audio w formacie `.wav`,
3. aplikacja odczytuje próbki sygnału i wyświetla jego przebieg czasowy,
4. sygnał zostaje podzielony na ramki o ustalonej długości (możliwa zmiana w interfejsie),
5. dla każdej ramki obliczane są wybrane parametry w dziedzinie czasu,
6. analogicznie ramki są grupowane w klipy o ustalonej długości (możliwa zmiana w interfejsie)
7. dla każdego klipu obliczane są wybrane parametry w dziedzinie czasu
8. wyniki prezentowane są w formie wykresów.
9. możliwość zapisu wybranych parametrów do pliku txt (tylko parametry aktualnie wyświetlane na wykresie i zaznaczone checkboxem są zapisywane do pliku)

2.2 Technologie i środowisko

Aplikacja została wykonana w języku C++ jako program okienkowy. Ze względu na charakter projektu wybrano środowisko umożliwiające jednoczesną obsługę interfejsu graficznego oraz wygodne operacje na danych audio. Projekt jest związany z frameworkiem JUCE i zawiera konfigurację typową dla aplikacji C++/JUCE.

Element	Zastosowanie	Uzasadnienie wyboru
Język programowania C++	implementacja logiki programu i obliczeń na próbkach audio	wysoka wydajność, dobra kontrola nad danymi i szerokie zastosowanie w aplikacjach audio
Framework JUCE	budowa aplikacji okienkowej, obsługa komponentów GUI, integracja z przetwarzaniem audio	popularne narzędzie do projektów audio, wygodne tworzenie interfejsu i przenośność
ImGui + Implot	budowa modularnego i skalowalnego GUI aplikacji, wyświetlanie wykresów	łatwość implementacji, wysoka jakość renderowanych wykresów (możliwość przesuwania, przybliżania)

Tabela 1. Zestawienie technologii wykorzystanych w projekcie.

Jak pokazano w tabeli 1, dobór technologii był podporządkowany prostocie implementacji aplikacji z interfejsem graficznym oraz sprawnemu wykonywaniu obliczeń na sygnale audio.

2.3 Interfejs użytkownika

Interfejs aplikacji został zaprojektowany w sposób umożliwiający szybkie przejście od wczytania pliku do obserwacji wyników. Główne elementy interfejsu obejmują:

- przycisk wyboru pliku `.wav` (File -> Load),
- przycisk zapisu wybranych parametrów do pliku TXT (Export -> Save parameters as TXT)
- obszar wyświetlania przebiegu czasowego sygnału,
- sekcję prezentującą wyznaczone parametry na poziomime ramki (możliwość wyboru),
- sekcję prezentującą wyznaczone parametry na poziomie klipu (możliwość wyboru)

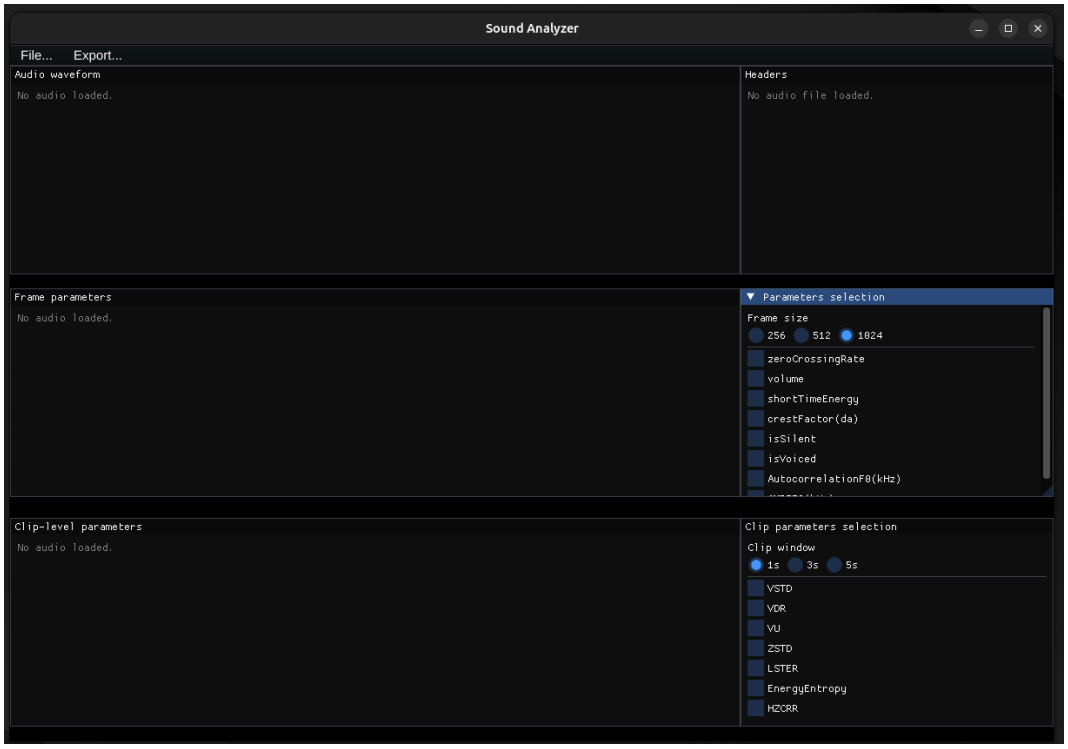

Rysunek 1. Główne okno aplikacji.

Rysunek 2. Główne okno aplikacji po wczytaniu audio i wybraniu kilku parametrów.

Rysunek 2 przedstawia główny widok programu po wczytaniu pliku audio. Na tym etapie użytkownik ma dostęp do podstawowych funkcji aplikacji oraz do wizualizacji analizowanego sygnału.

3 Opis metod

3.1 Wczytywanie i reprezentacja sygnału

Pierwszym etapem działania programu jest odczyt danych z pliku `.wav`. Format ten przechowuje próbki sygnału audio zapisane z określoną częstotliwością próbkowania, rozdzielczością bitową oraz liczbą kanałów. Po wczytaniu pliku dane są reprezentowane w aplikacji jako ciąg próbek amplitudy w funkcji czasu.

Przebieg czasowy sygnału jest następnie prezentowany na wykresie, co pozwala użytkownikowi ocenić ogólną strukturę nagrania, zauważyć fragmenty o dużej i małej energii oraz wstępnie wskazać odcinki ciszy lub aktywności.

3.2 Analiza ramkowa

W praktyce wiele cech sygnału audio wyznacza się nie dla całego nagrania jednocześnie, lecz lokalnie, dla krótkich fragmentów nazywanych ramkami. Takie podejście wynika z faktu, że sygnał audio zwykle zmienia swoje własności w czasie. Podział na ramki pozwala opisać te zmiany bardziej szczegółowo.

3.3 Parametry ramek w dziedzinie czasu

W aplikacji wyznaczane są cechy sygnału audio w dziedzinie czasu na poziomie pojedynczych ramek. Analiza ramkowa pozwala opisywać lokalne własności nagrania, które zmieniają się w czasie. W ramach projektu wykorzystano miary głośności, energii krótkoterminowej, liczby przejść przez zero, detekcji ciszy oraz estymacji częstotliwości tonu podstawowego F_0.

Parametr	Wzór
Volume (głośność)	$$p(n) = \sqrt{\frac{1}{N}\sum_{i=0}^{N-1} s_n^2(i)}$$
Short Time Energy (STE)	$$STE(n) = \frac{1}{N}\sum_{i=0}^{N-1} s_n^2(i) = p(n)^2$$
Zero Crossing Rate (ZCR)	$$Z(n) = \frac{1}{2N}\left(\sum_{i=1}^{N-1} \lvert\mathrm{sign}(s_n(i)) - \mathrm{sign}(s_n(i-1))\rvert\right)$$
Autokorelacja	$$R_n(l) = \sum_{i=0}^{N-l-1} s_n(i)\, s_n(i+l)$$
AMDF	$$A_n(l) = \sum_{i=0}^{N-l-1} \lvert s_n(i+l) - s_n(i)\rvert$$

Tabela 2. Parametry analizowane w dziedzinie czasu na poziomie ramki.

Tabela 2 przedstawia zestaw cech wykorzystanych w aplikacji. Wszystkie parametry obliczane są dla kolejnych ramek sygnału, co umożliwia śledzenie zmian własności nagrania w czasie.

Volume – głośność

Miara głośności wyznacza średni poziom sygnału audio w krótkim fragmencie nagrania. W projekcie głośność została aproksymowana jako pierwiastek średniej energii sygnału w ramce:

$$p(n) = \sqrt{\frac{1}{N}\sum_{i=0}^{N-1} s_n^2(i)},$$

gdzie N oznacza długość ramki w próbkach, natomiast $s_n(i)$ oznacza amplitudę i-tej próbki w n-tej ramce.

Parametr ten jest szczególnie użyteczny przy analizie lokalnej aktywności sygnału. Dla fragmentów zawierających mowę lub dźwięk o większej amplitudzie wartość głośności rośnie, natomiast dla ciszy lub bardzo słabego sygnału maleje. Należy jednak zauważyć,

że wartość ta zależy również od ogólnego poziomu nagrania, dlatego w praktyce jej interpretacja może wymagać normalizacji.

STE – Short Time Energy

Short Time Energy jest miarą energii sygnału w obrębie jednej ramki i stanowi kwadrat miary głośności:

$$STE(n) = \frac{1}{N} \sum_{i=0}^{N-1} s_n^2(i) = p(n)^2.$$

STE dobrze opisuje lokalną intensywność sygnału. Wysokie wartości pojawiają się zwykle dla fragmentów dźwięcznych i aktywnych, natomiast niskie dla ciszy lub fragmentów bezdźwięcznych. Parametr ten jest prosty obliczeniowo i często wykorzystywany jako jedno z podstawowych kryteriów detekcji ciszy.

ZCR – Zero Crossing Rate

Zero Crossing Rate określa liczbę przejść sygnału przez zero w obrębie jednej ramki:

$$Z(n) = \frac{1}{2N} \left(\sum_{i=1}^{N-1} |\mathrm{sign}(s_n(i)) - \mathrm{sign}(s_n(i-1))| \right).$$

Miara ta dobrze opisuje szybkość zmian sygnału. Dla fragmentów bardziej szumowych lub bezdźwięcznych wartość ZCR jest zwykle większa, natomiast dla fragmentów dźwięcznych mniejsza. Z tego powodu współczynnik ten jest często stosowany razem z miarą głośności lub energii, szczególnie przy klasyfikacji fragmentów nagrania.

SR – Silent Ratio / detekcja ciszy

Detekcja ciszy w projekcie opiera się na analizie cech wyznaczanych dla kolejnych ramek. Jeżeli wartość głośności oraz współczynnika ZCR dla danej ramki spada poniżej przyjętego poziomu, ramka może zostać sklasyfikowana jako cisza.

Takie podejście pozwala odróżniać rzeczywiste fragmenty ciszy od fragmentów zawierających sygnał o małej energii, lecz nadal wykazujących znaczną zmienność. Zaletą tej metody jest prostota oraz niski koszt obliczeniowy. Jej skuteczność zależy jednak od poprawnego doboru progów decyzyjnych oraz długości ramki.

Częstotliwość tonu podstawowego F_0

Kolejną analizowaną cechą jest częstotliwość tonu podstawowego F_0. Jej estymacja została oparta na funkcji autokorelacji lub funkcji AMDF (*Average Magnitude Difference Function*).

Autokorelacja dla n-tej ramki wyraża się wzorem:

$$R_n(l) = \sum_{i=0}^{N-l-1} s_n(i)\, s_n(i+l),$$

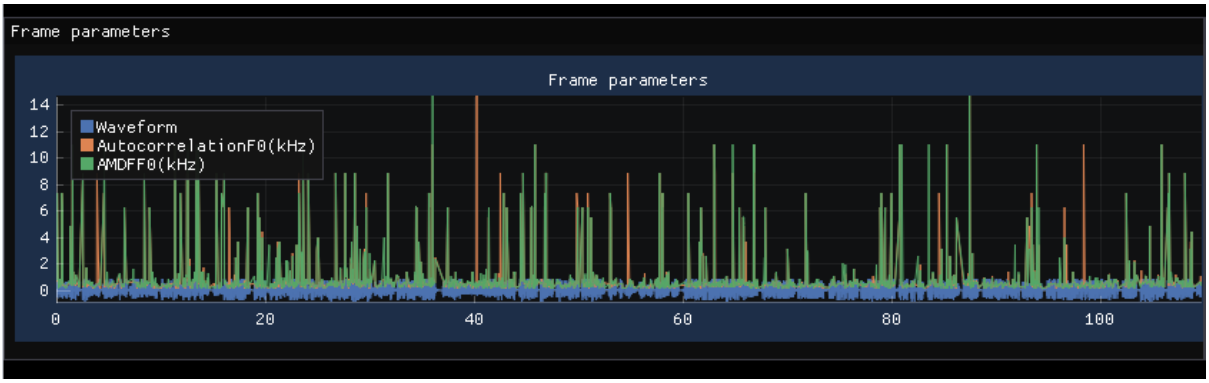

Rysunek 3. Wyniki wyznaczania częstotliwości tonu podstawowego na nagraniu rozmowy żeńsko-męskiej.

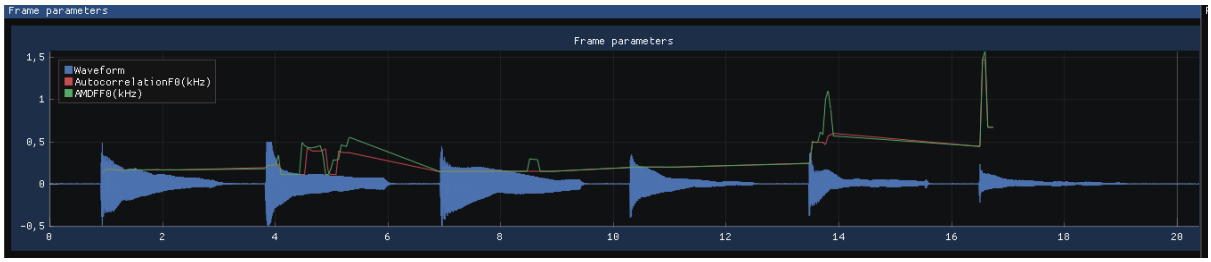

Rysunek 4. Częstotliwości tonu podstawowego metodą AMDF i Autokorelacji dla nagrania dźwięku kolejnych strun gitary

natomiast funkcja AMDF ma postać:

$$A_n(l) = \sum_{i=0}^{N-l-1} |s_n(i+l) - s_n(i)|.$$

W obu przypadkach analizuje się zależność sygnału od jego opóźnionej wersji. Na tej podstawie można wyznaczyć okres tonu podstawowego, a następnie obliczyć częstotliwość F_0. Parametr ten ma szczególne znaczenie przy analizie mowy i sygnałów quasi-okresowych. W praktyce jego estymacja może być mniej stabilna dla sygnałów zaszumionych, bezdźwięcznych lub bardzo krótkich ramek.

Zbadaliśmy zachowanie się wyznaczanej częstotliwości tonu podstawowego na nagraniu zawierającym rozmowę kobiety i mężczyzny (głos żeńsko-męski). Wyniki przedstawia Rysunek 3.

Wykresy wartości częstotliwości tonu podstawowego idealnie ukazują różnice między głosem żeńskim, a męskim na nagraniu radiowym.

Zbadano również wartości F0 dla nagrania dźwięku kolejnych strun gitary, aby zbadać dokładność wyznaczania częstotliwości tonu podstawowego metodą AMDF/Autokorelacji. Wyniki przedstawia Rysunek 4.

Wyniki analizy ukazują gradację częstotliwości każdej ze strun - od najmniejszej do największej - jednak widac, iż jakkość wyznaczonego F0 nie jest zbyt dokładna. Wykres często się „gubo” po drodze, a wyliczone wartości nie do końca odpowiadają przewidywaniom teorytycznym dla dźwięku strun gitary.

3.4 Detekcja ciszy

Detekcja ciszy w projekcie została zrealizowana na podstawie dwóch parametrów wyznaczanych dla każdej ramki sygnału: głośności (*Volume*) oraz współczynnika przejść przez zero (*ZCR*). Ramka zostaje zaklasyfikowana jako cisza tylko wtedy, gdy spełnione są jednocześnie dwa warunki: wartość parametru Volume jest mniejsza od ustalonego progu *volumeThreshold* oraz wartość parametru ZCR jest mniejsza od progu *zcrThreshold*.

Można to zapisać w postaci warunku:

$$\text{cisza} \iff \big(Volume < T_V\big) \wedge \big(ZCR < T_Z\big),$$

gdzie T_V oznacza próg dla głośności, a T_Z próg dla współczynnika przejść przez zero.

Takie podejście pozwala ograniczyć liczbę błędnych klasyfikacji. Sama niska wartość głośności nie zawsze oznacza ciszę, ponieważ w sygnale mogą występować ciche, ale nadal istotne fragmenty. Z kolei uwzględnienie dodatkowo parametru ZCR pozwala odróżnić rzeczywistą ciszę od fragmentów zawierających drobne zakłócenia lub sygnał o niewielkiej amplitudzie, ale większej zmienności.

Eksperymentalne wyznaczanie progów

Wartości progowe dla parametrów Volume i ZCR zostały dobrane eksperymentalnie. Najpierw ustalono je na podstawie jednego wybranego nagrania, obserwując, dla jakich wartości detekcja ciszy daje satysfakcjonujące wyniki. Nagranie testowe było odsłuchiwane w programie *Audacity*, aby zwrócić uwagę czy w danym momencie jest cisza, czy też występuje szum. Ustalono progi początkowo: $volumeThreshold = 0.01$ oraz $zcrThreshold = 0.1$.

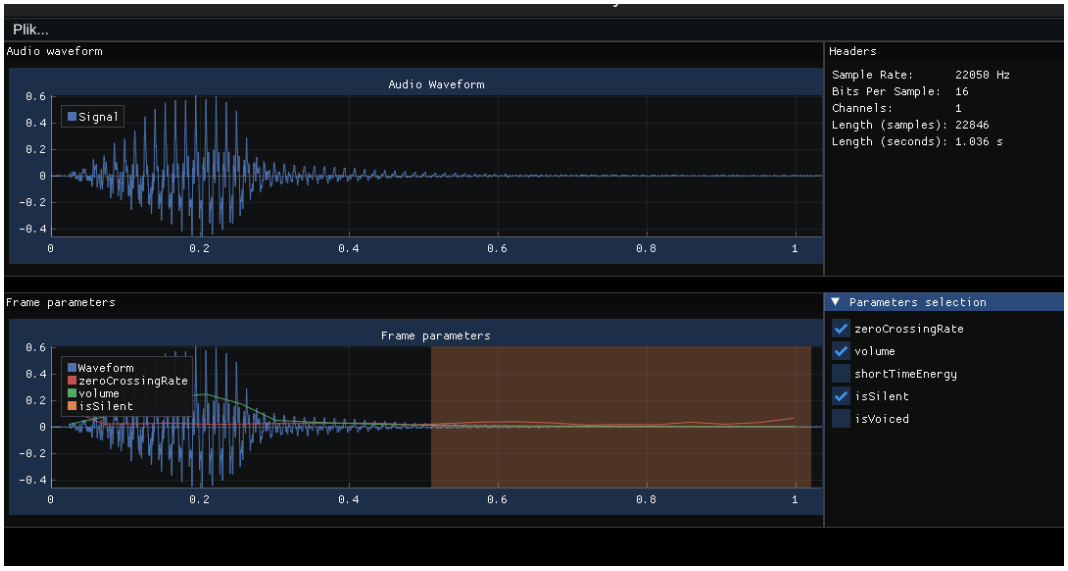

Rysunek 5. Początkowe ustalanie progu

Następnie te same progi przetestowano na innym nagraniu :

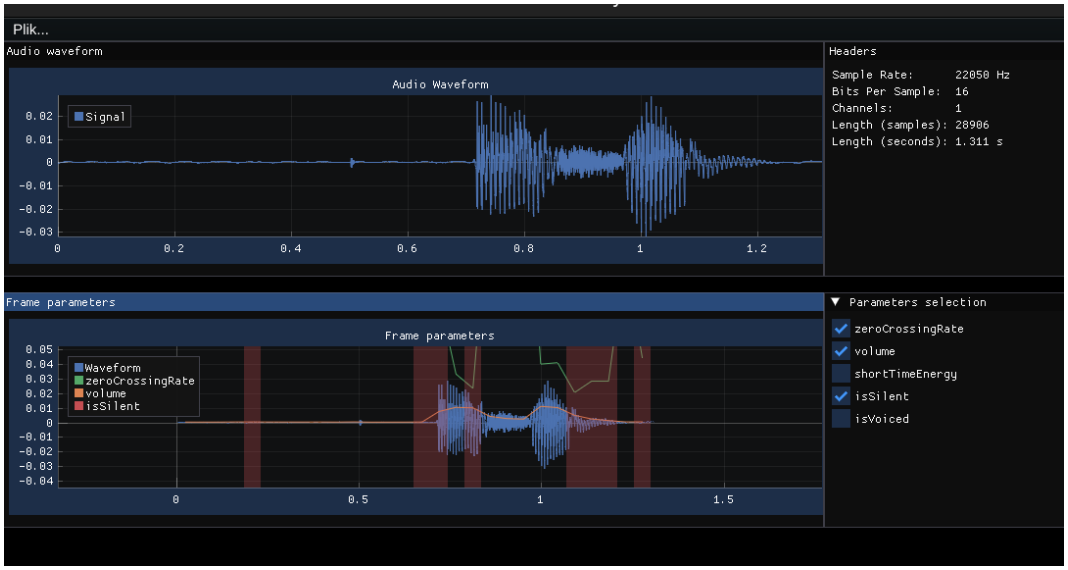

Rysunek 6. Potwierdzenie ustalonego progu

Działanie algorytmu również w tym przypadku było poprawne. Na powyższym rysunku na początku słychać szum, dlatego pomimo pratycznie zerowego Volume ZCR przekracza próg i nie zostaje dlatego sklasyfikowane jako cisza. Przyjęte wartości pozostawiono jako końcowe ustawienie metody. Taki sposób doboru progów pozwolił uzyskać prosty i praktyczny mechanizm detekcji, który działa poprawnie dla analizowanych w projekcie sygnałów.

Dodatkowo zrobiono test na nagraniu, które jest czystą ciszą - brak szumu.

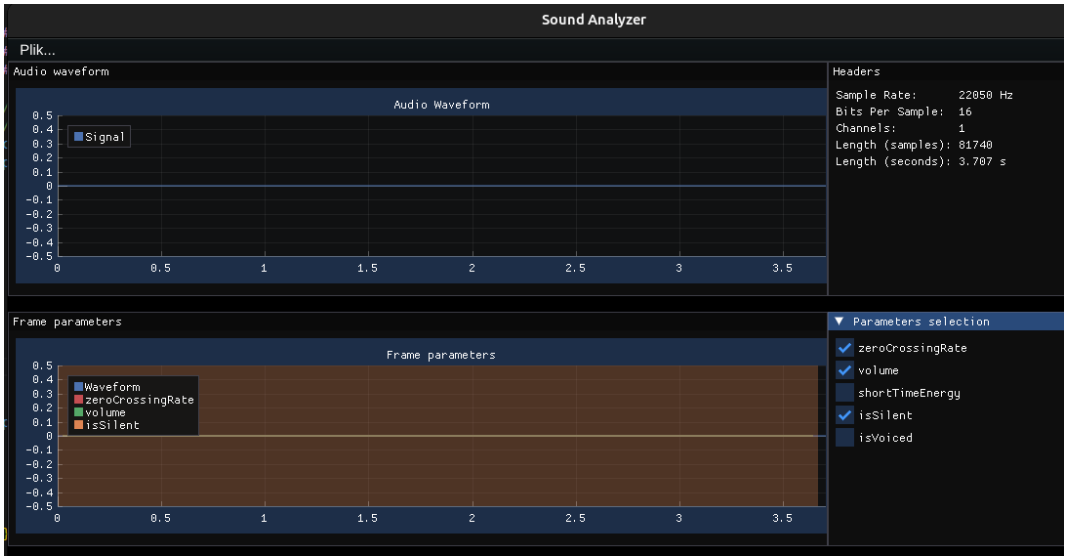

Rysunek 7. Nagranie będące ciszą

Nasz program zgodnie z oczekiwaniam zaznacza całe nagranie jako ciszę.

Zaletą zastosowanej metody jest prostota implementacji oraz niewielki koszt obliczeniowy. Ograniczeniem pozostaje jednak to, że skuteczność algorytmu zależy od odpowiedniego doboru progów decyzyjnych. W przypadku nagrań o innym poziomie głośności, większym zaszumieniu lub innej charakterystyce sygnału konieczne może być ponowne

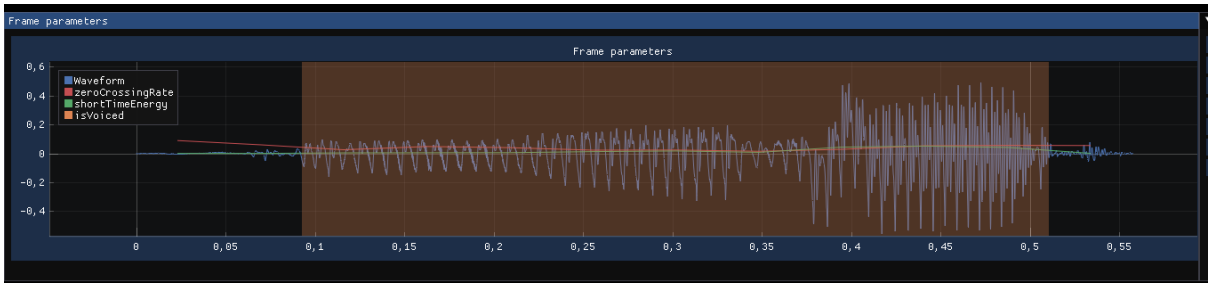

Rysunek 8. Wyniki klasyfikacji ramek jako dźwięczne na słowie zero

dostrojenie parametrów.

3.5 Określanie fragmentów dźwięcznych i bezdźwięcznych

W projekcie zaimplementowano również mechanizm klasyfikacji ramek jako dźwięczne lub bezdźwięczne. Decyzja podejmowana jest na podstawie dwóch parametrów: współczynnika przejść przez zero (ZCR) oraz energii krótkoterminowej (STE). Ramka jest uznawana za dźwięczną wtedy, gdy wartość ZCR jest mniejsza od ustalonego progu, a jednocześnie wartość STE jest większa od drugiego progu decyzyjnego.

Warunek ten można zapisać następująco:

$$\text{ramka dźwięczna} \iff \Big(ZCR < T_Z\Big) \wedge \Big(STE > T_{STE}\Big),$$

gdzie T_Z oznacza próg dla współczynnika przejść przez zero, natomiast T_{STE} oznacza próg dla energii krótkoterminowej.

Takie podejście jest zgodne z charakterystyką sygnałów mowy i wielu innych sygnałów audio. Fragmenty dźwięczne zwykle charakteryzują się większą energią oraz bardziej uporządkowaną strukturą, co przekłada się na niższe wartości ZCR. Z kolei fragmenty bezdźwięczne są często bardziej nieregularne i mają wyższy ZCR, a ich energia może być mniejsza.

Eksperymentalne wyznaczenie progów

Wartości progowe dla parametrów ZCR i STE zostały dobrane eksperymentalnie tą samą metodą, co w przypadku detekcji ciszy. Najpierw ustalono progi na podstawie jednego wybranego nagrania, obserwując poprawność klasyfikacji ramek. Zdecydowano się użyć znormalizowanego nagrania słowa "zero", które składa się z samych dźwięcznych głosek. Wynik przedstawiono na Rysunku 8.

Na podstawie tego jednego nagrania dobrano próg STE **0.002** oraz ZCR **0.1**. Widać, że tak dobrane progi na nagraniu obejmują głoski i nie dopasowują się do szumu na początku i na końcu dźwięku, kiedy to rozpoczyna się zbieranie mowy i głoski jeszcze mogą być niestabilne.

Następnie te same wartości przetestowano na innych nagraniach, aby sprawdzić jak wyznaczone na początku progi się generalizują. Pierwszy problem napotkano na nagraniu „abe”, którego parametry przedstawiono na Rysunku 9.

Postanowiono dostosować parametry - zmieniono próg STE na **0.0015**. Wyniki przedstawia Rysunek 10.

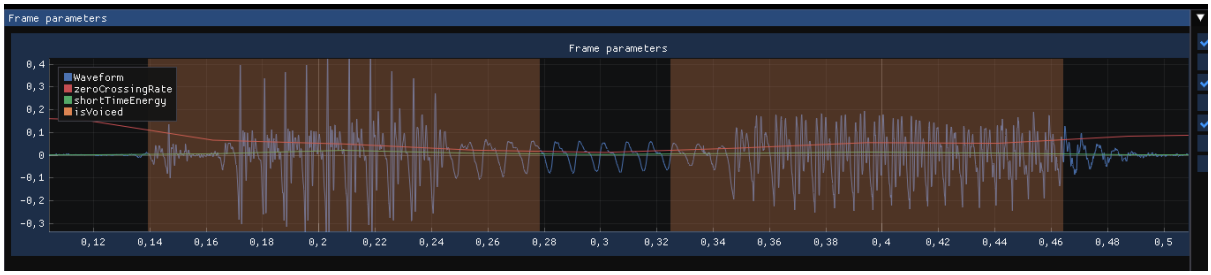

Rysunek 9. Detekcja dźwięczności słowa „abe” dla progów STE 0.002 i ZCR 0.1

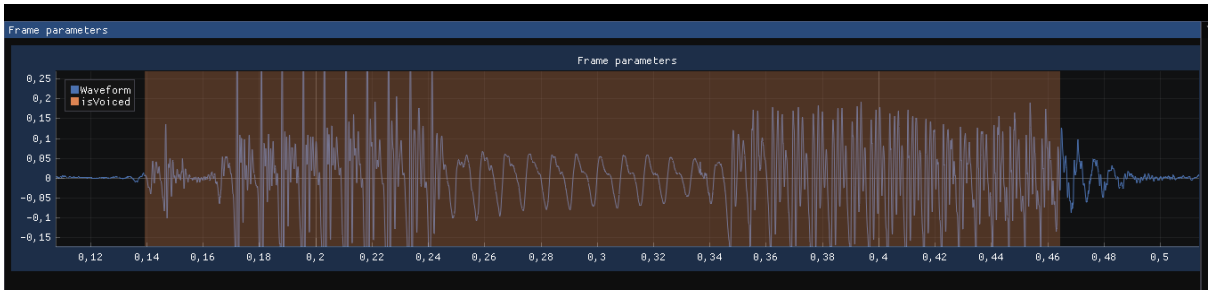

Rysunek 10. Detekcja dźwięczności słowa „abe” dla progów STE 0.0015 i ZCR 0.1

Tym razem detekcja dźwięczności objęła całe słowo. Zbadano również zachowanie się mechanizmu klasyfikacji na słowach zawierających głoski dźwięczne i bezdźwięczne jednocześnie. Test na przykładowym słowie „chrząszcz” przedstawia Rysunek 11.

Jak można łatwo się domyślić, zaznaczony fragment jako dźwięczny to głoska „ą”. Reszta dźwięku to głoski „sz” oraz „cz”.

Po dalszych testach nie zauważono znaczących błędów w klasyfikacji audio jako dźwięczne i ostatecznie zdecydowano się pozostać przy tak dobranych progach.

Ciekawy wynik uzyskano jednak dla słowa „zit”, przedstawiony na Rysunku 12.

Jak widać fragment głoski „t” został oznaczony jako dźwięczny. Potencjalnym wyjaśnieniem tego zjawiska jest fakt, iż przejściowy charakter samego wybuchu powietrza sprawia, że współczynnik przejść przez zero (ZCR) pozostaje na stosunkowo niskim poziomie, zmuszając algorytm do zinterpretowania tego fragmentu jako sygnał dźwięczny.

3.6 Crest Factor – współczynnik szczytu (własny parametr)

W projekcie jako implementację czegoś dodatkowego do analizy dźwięku w dziedzinie czasu zdecydowano się dodać Crest Factor.

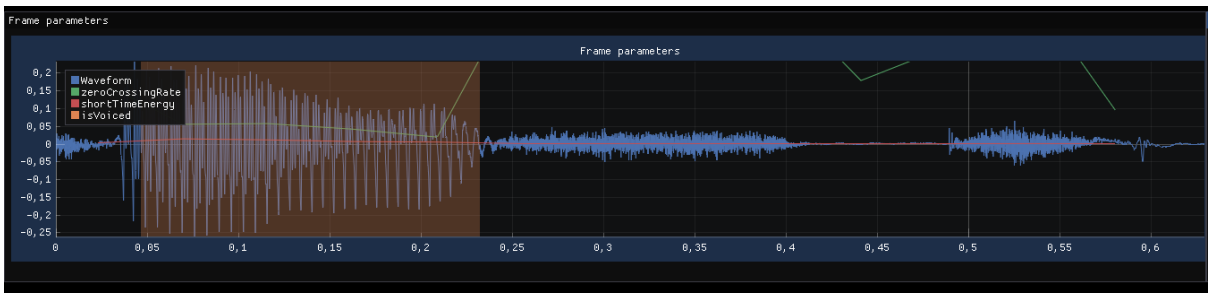

Rysunek 11. Detekcja dźwięczności słowa „chrząszcz” dla progów STE 0.0015 i ZCR 0.1

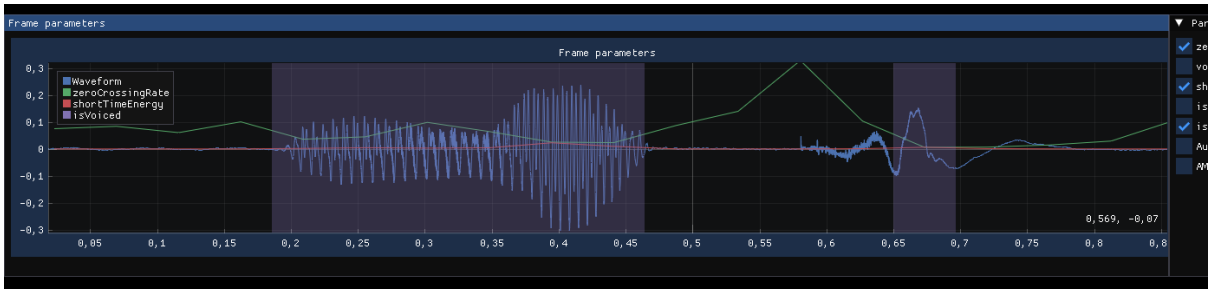

Rysunek 12. Detekcja dźwięczności dla słowa „zit”

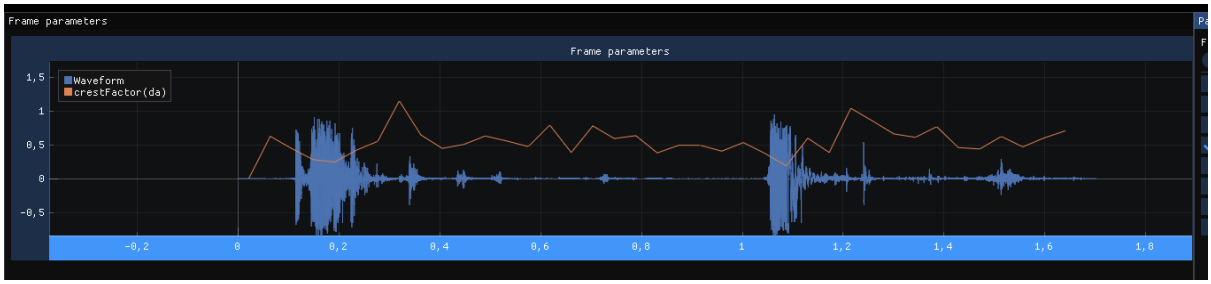

Rysunek 13. Współczynnik szczytu na trzasku łamania drewna (powtórzonego 2 razy)

Współczynnik szczytu (ang. *Crest Factor*) określa stosunek wartości szczytowej (maksymalnej) amplitudy sygnału w danej ramce do jego wartości skutecznej (RMS), która odpowiada opisanej wcześniej mierze głośności (*Volume*). Dla n-tej ramki parametr ten wyraża się wzorem:

$$CF(n) = \frac{\max_{i=0}^{N-1} |s_n(i)|}{p(n)}$$

gdzie $\max_{i=0}^{N-1} |s_n(i)|$ oznacza największą wartość bezwzględną amplitudy próbek w n-tej ramce, natomiast $p(n)$ to wyznaczona dla tej ramki głośność.

Parametr ten dostarcza informacji o dynamice i kształcie przebiegu sygnału w krótkim oknie czasowym. Wysokie wartości współczynnika szczytu wskazują na występowanie nagłych, impulsowych zmian o dużej amplitudzie na tle stosunkowo niskiej energii średniej, co jest charakterystyczne między innymi dla uderzeń instrumentów perkusyjnych, transjentów czy trzasków. Niskie wartości świadczą z kolei o sygnale o bardziej wyrównanym poziomie amplitudy, zbliżonym do fali ciągłej lub gęstego szumu. Analiza parametru *Crest Factor* stanowi użyteczne uzupełnienie miar energii i głośności, pomagając w dokładniejszej klasyfikacji i segmentacji analizowanych fragmentów audio.

Zbadano zachowanie się parametru na nagraniu trzasku łamanego drewna oraz klaskania. Wyniki przedstawiamy na Rysunkach 13 14.

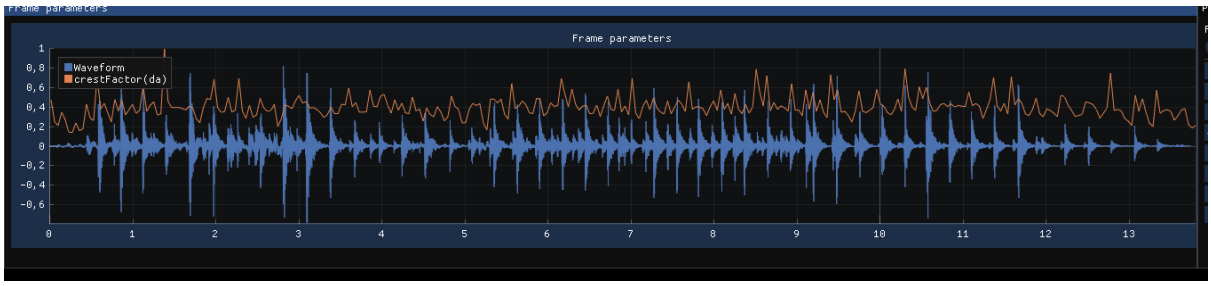

Rysunek 14. Współczynnik szczytu na dźwięku ciągłego, pojedynczego klaskania

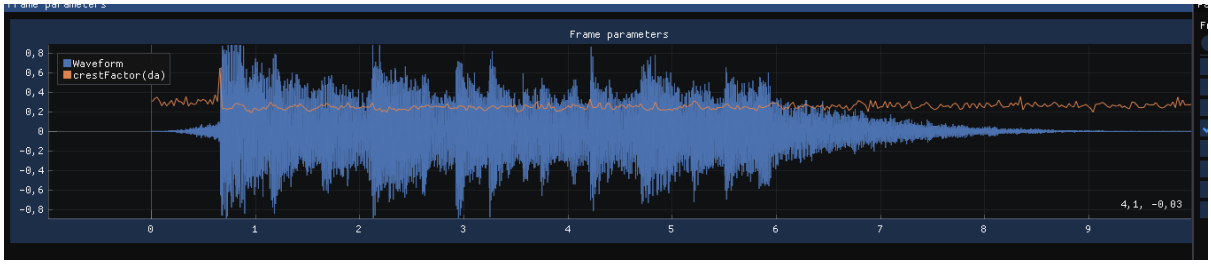

Rysunek 15. Współczynnik szczytu dla fragmentu gry na pianinie

Tak jak opis teorytyczny sugerował, crest factor idealnie odwozorwouje nagłe, impulsowe zmiany w nagraniu. Na obu nagraniach widac pofalowanie i dużo peaków dla tego typu nagrań.

Ciekawy efekt uzyskano dla nagrania fragmentu gry na pianinie. Wyniki przedstawia Rysunek.

Nietrudno zauważyć, iż w momencie rozpoczęcia nagrania przyjmuje on bardzo dużą wartość. Wytłumaczenie tego zjawiska to fakt, iż na początku mamy nagłą, impulsową zmianę w nagraniu - dokładnie to, co crest factor miał oznaczać. Dalej widzimy pewne wahania tego współczynnika, które przyjmują jednak znacznie niższe wartości niż dla dźwięku trzasku czy klaskania.

3.7 Analiza na poziomie klipu

Z kolei analiza na poziomie klipu polega na grupowaniu wielu sąsiadujących ze sobą ramek w dłuższe okna czasowe. Pozwala to na badanie statystyk i długoterminowych zmian cech wyznaczonych wcześniej lokalnie. Dzięki takiemu podejściu możliwe jest uchwycenie szerszego kontekstu brzmieniowego oraz określenie zawartości semantycznej analizowanego fragmentu nagrania.

3.8 Parametry klipów w dziedzinie czasu

Podczas gdy cechy na poziomie pojedynczych ramek pozwalają na analizę krótkookresowych właściwości nagrania, wiele istotnych informacji semantycznych wymaga obserwacji zmian w dłuższym oknie czasowym. W tym celu wyznacza się parametry na poziomie klipu (zbioru kilkunastu lub kilkudziesięciu ramek), które opisują dynamikę i statystyki zmienności cech ramkowych. W projekcie rozważono miary bazujące na głośności, energii oraz współczynniku przejść przez zero.

VSTD – Standard Deviation normalized by the maximum volume

Odchylenie standardowe znormalizowane przez maksymalną głośność w klipie (VSTD) jest miarą statystyczną wyliczaną na podstawie zmian parametru Volume. Pozwala ona określić, jak bardzo głośność w danym fragmencie odchyla się od wartości średniej, przy jednoczesnym uniezależnieniu wyniku od ogólnej głośności całego nagrania (dzięki normalizacji względem piku głośności). Miara ta jest przydatna do analizy dynamiki sygnału.

VDR – Volume Dynamic Range

Zakres dynamiki głośności (VDR) to kolejny parametr bazujący na głośności ramkowej, który opisuje rozpiętość między najcichszym a najgłośniejszym momentem w obrębie całego klipu. Wyznacza się go za pomocą wzoru:

$$VDR = \frac{\max(v) - \min(v)}{\max(v)}$$

gdzie $\min(v)$ oraz $\max(v)$ oznaczają odpowiednio minimalną i maksymalną wartość głośności zarejestrowaną w analizowanym klipie audio. Parametr ten pozwala łatwo zidentyfikować nagrania o płaskiej dynamice w stosunku do tych o dużych skokach głośności.

VU – Volume Undulation

Falistość głośności (VU) charakteryzuje się poprzez nagromadzenie różnic pomiędzy sąsiednimi lokalnymi maksimami (pikami) oraz minimami (dolinami) dla konturu głośności w całym klipie. Parametr ten dobrze sprawdza się w detekcji sygnałów o wyraźnej, rytmicznej strukturze zmian amplitudy, takich jak mowa czy muzyka z wyraźnym bitem, w przeciwieństwie do jednostajnego szumu.

LSTER – Low Short Time Energy Ratio

Współczynnik LSTER bazuje na parametrze STE i określa odsetek liczby ramek w klipie, w których energia krótkoterminowa jest mniejsza niż 50% średniej energii w oknie jednosekundowym. Wyraża się go wzorem:

$$LSTER = \frac{1}{2N} \sum_{n=0}^{N-1} [\mathrm{sgn}(0.5 \cdot avSTE - STE(n)) + 1]$$

gdzie N jest całkowitą liczbą ramek w klipie, $STE(n)$ to energia dla n-tej ramki, a $avSTE$ oznacza średnią wartość STE w jednosekundowym oknie. Miara ta jest wysoce efektywna w rozróżnianiu mowy od muzyki. Sygnał mowy charakteryzuje się dużą liczbą naturalnych pauz i przerw, co skutkuje wyższą wartością LSTER niż w przypadku typowego sygnału muzycznego.

Energy Entropy – entropia energii

Entropia energii jest miarą wyliczaną poprzez podział ramki audio na segmenty składające się z K próbek. Dla każdego segmentu obliczana jest energia, którą następnie normalizuje się przez całkowitą energię ramki. Entropię energii I wyznacza się z zależności:

$$I = -\sum_{i=1}^{J} \sigma_i^2 \log_2 \sigma_i^2$$

gdzie J jest całkowitą liczbą segmentów w klipie, a σ_i^2 oznacza znormalizowaną energię dla i-tego segmentu. Parametr ten jest bardzo użyteczny przy wykrywaniu nagłych zmian i sygnałów o charakterze impulsowym (tzw. sceny „wybuchowe”, wystrzały, uderzenia).

ZSTD – Standard Deviation of the ZCR

Odchylenie standardowe współczynnika przejść przez zero (ZSTD) określa zmienność parametru ZCR w obrębie klipu. Badania wykazują użyteczność statystyk opartych na ZCR przy podziale nagrań na podstawowe kategorie, takie jak mowa i muzyka, ponieważ sygnały te charakteryzują się odmienną stabilnością wtrąceń wysokoczęstotliwościowych oraz szumowych.

HZCRR – High Zero Crossing Rate Ratio

Podobnie jak LSTER dla energii, parametr HZCRR określa odsetek ramek, w których współczynnik przejść przez zero jest wyższy niż 1.5 raza średnia wartość ZCR w oknie jednosekundowym. Parametr ten jest obliczany następująco:

$$HZCRR = \frac{1}{2N} \sum_{n=0}^{N-1} [\mathrm{sgn}(ZCR(n) - 1.5 \cdot avZCR) + 1]$$

gdzie N to całkowita liczba ramek, $ZCR(n)$ to wartość ZCR w n-tej ramce, a $avZCR$ to średnia wartość tego parametru. Miara ta wspomaga analizę sygnałów pod kątem występowania nagłych szumów oraz bezdźwięcznych fragmentów mowy.

3.9 Klasyfikacja klipów mowa/muzyka

W oparciu o wyznaczone parametry na poziomie klipu zaimplementowano mechanizm klasyfikacji fragmentów nagrania jako mowa lub muzyka. Rozróżnienie to opiera się na analizie zestawu cech, które w odmienny sposób opisują długoterminową charakterystykę obu typów sygnałów. Decyzja podejmowana jest dla każdego klipu z wykorzystaniem progów decyzyjnych dobranych dla wybranych parametrów statystycznych.

Klasyfikacja mowy

Sygnał mowy charakteryzuje się występowaniem naturalnych pauz, wysoką dynamiką zmian głośności oraz obecnością bezdźwięcznych głosek o charakterze szumowym. W aplikacji dany klip klasyfikowany jest jako mowa, gdy spełnione są jednocześnie trzy warunki: odsetek ramek o niskiej energii ($LSTER$) przekracza próg 0.2, odsetek ramek o wysokim współczynniku przejść przez zero ($HZCRR$) jest większy niż 0.09, a zakres dynamiki głośności (VDR) przyjmuje wartość powyżej 0.7. Warunek ten można zapisać następująco:

$$\text{mowa} \iff (LSTER > 0.2) \wedge (HZCRR > 0.09) \wedge (VDR > 0.7)$$

Takie zestawienie parametrów pozwala skutecznie odizolować fragmenty mowy, opierając się na jej przerywanym charakterze oraz występowaniu spółgłosek.

Powyższe progi zostały wyznaczone doświadczalnie, na podstawie dwóch nagrań - fragmentów audycji radiowej Programu Trzeciego Polskiego Radia (wywiad na żywo, głos męski i żeński) oraz fragment audycji przedstawiający rozmowę na żywo prezentera (głos wysokiej jakości) z jednym ze słuchaczy (rozmowa telefoniczna). Podobnie jak wcześniej -

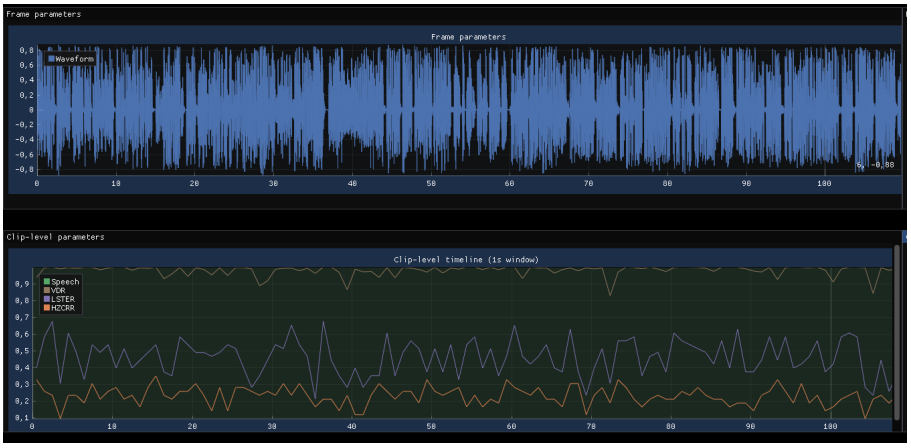

Rysunek 16. Wyniki klasyfikacji mowy na nagraniu audycji z głosem żeńsko-męskim

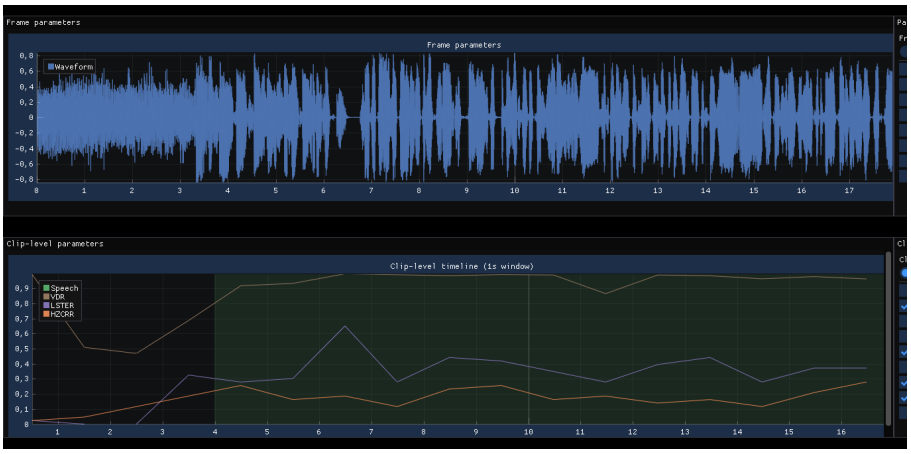

Rysunek 17. Wyniki klasyfikacji mowy na nagraniu audycji z głosem męskim + rozmowa telefoniczna

najpierw wyznaczono minimalne progi, które zapewniły poprawną klasyfikację klipów dla pierwszego nagrania, a następnie minimalnie je przesunięto bazując na zachowaniu się mechanizmu klasyfikacji na drugim nagraniu. Wyniki przedstawiono na Rysunkach 16 17.

Jak widać oba nagrania zostały zaklasyfikowane poprawnie. Drugie przez pierwsze kilka sekund zawiera melodię zapowiedzi i głos lektora z radia, dlatego tamte klipy nie zostały oznaczone jako czysta mowa. Dało to też ważny wniosek - taka metoda klasyfikacji nie radzi sobie z kombinacją mowy i muzyki jednocześnie (przynajmniej dla testowanego fragmentu nagrania).

Klasyfikacja muzyki

Z kolei sygnały muzyczne cechują się zazwyczaj większą ciągłością dźwięku (mniejsza liczba zauważalnych przerw), wyczuwalnymi rytmicznymi zmianami amplitudy oraz wyższą stabilnością współczynnika przejść przez zero. Zgodnie z zaimplementowanym algorytmem, klip uznawany jest za muzykę, jeżeli współczynnik $LSTER$ jest mniejszy od 0.4, falistość głośności (VU) przekracza próg 0.02, a odchylenie standardowe współczynnika przejść przez zero ($ZSTD$) przyjmuje wartość poniżej 0.025. Zależność tę wyraża wzór:

$$\text{muzyka} \iff (LSTER < 0.4) \wedge (VU > 0.02) \wedge (ZSTD < 0.025)$$

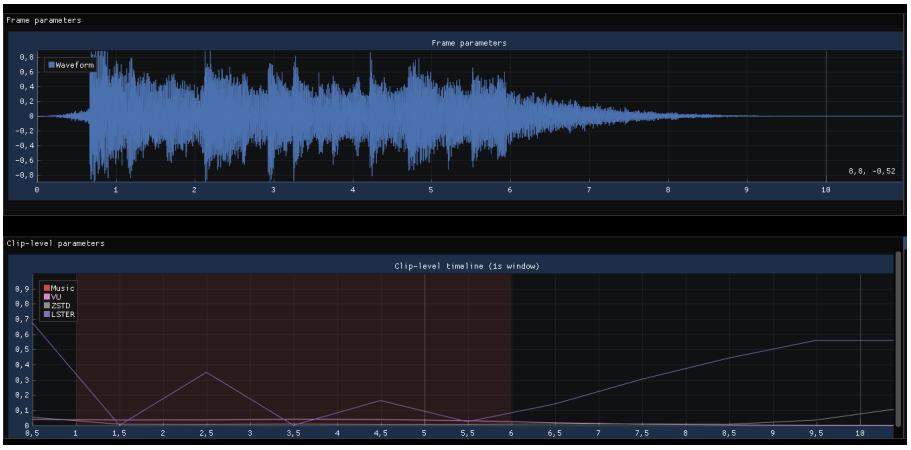

Rysunek 18. Wyniki klasyfikacji muzycznej dla fragmentu gry na pianinie

Rysunek 19. Wyniki klasyfikacji muzycznej dla fragmentu muzyki klasycznej

Dla muzyki przeprowadzono taki sam proces doświadczalnego wyznaczenia progów jak dla mowy. Wybrano krótki fragment nagrania zawierający same pianino oraz dłuższy fragment złożonej muzyki klasycznej. Wyniki po dostosowaniu parametrów przedstawiono na Rysunkach 18 19.

Klasyfikacja dla obu nagrań obejmuje wszystkie klipy zawierające fragmenty muzyki. Pianino pod koniec zawiera łagodne wyciszenie oraz fragment ciszy, dlatego tam klasyfikacja nie uznała ramek za muzykę. Warto również zwrócić uwagę, iż wartości poszczególnych parametrów, które wybrano do progowania mowy i muzyki dobrze odzwierciedlają oba typy nagrań.

Zbadano również jak oba klasyfikatory zachowują się dla swojego kontratypu, tzn mowy dla muzyki oraz muzyki dla mowy. Klasyfikator mowy nigdy nie zaklasyfikował muzyki do swojego typu, natomiast klasyfikator muzyki niektóre fragmenty mowy uznał za muzyczne. Wyniki przedstawiają Rysunki .

Nietrudno zauważyć, iż są to fragmenty, gdzie nagle spada wartość LSTR oraz ZSTD, przy wzrościie VU.

Poniżej przedstawiamy potencjalne wyjaśnienie dla każdego z parametrów klasyfikatora muzycznego:

- **LSTER $<$ 0.4** (niska liczba cichych ramek): Jeśli ktoś mówi szybko, w sposób ciągły,

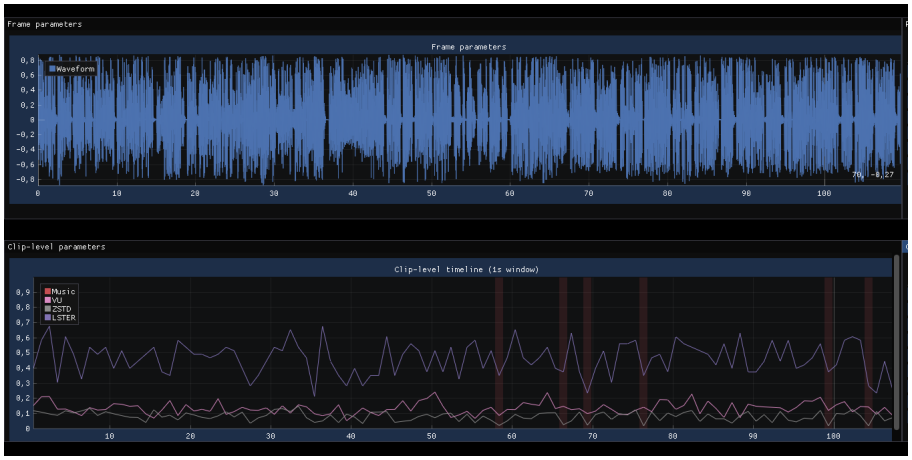

Rysunek 20. Wyniki klasyfikatora, wraz z jego parametrami, na nagraniu rozmowy żeńsko-męskiej

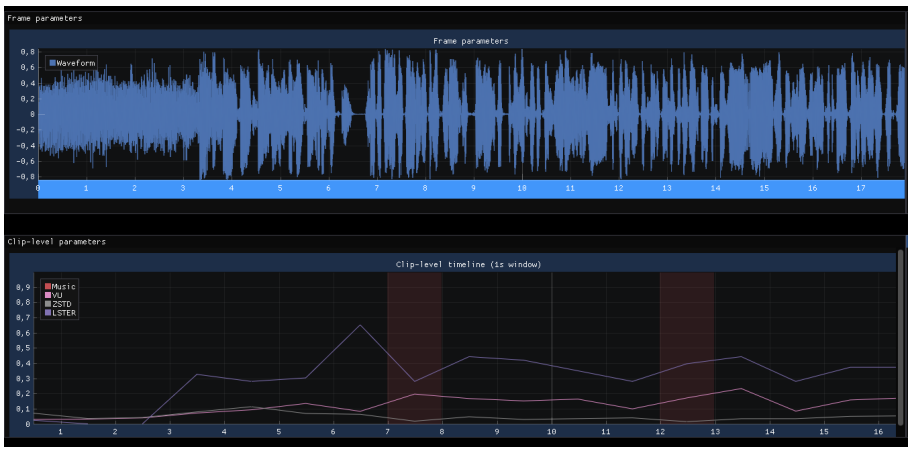

Rysunek 21. Wyniki klasyfikatora, wraz z jego parametrami, na nagraniu rozmowy męsko-telefonicznej

bez wyraźnych pauz i oddechów (lub w nagraniu występuje znaczny pogłos), energia sygnału rzadko spada poniżej średniej. Algorytm interpretuje ten brak przerw jako ciągłość dźwięku, która jest typowa dla instrumentów. Taki efekt zaobserwowano na fragmencie wywiadu, co jest często spotykane (szybka rozmowa, mało przerw) oraz podczas telefonicznych wypowiedzi słuchacza na antenie.

- **VU > 0.02** (wysoka falistość głośności): Mowa z natury opiera się na sylabach – składamy ją z głośniejszych samogłosek i cichszych spółgłosek. To tworzy naturalne "falowanie"amplitudy (VU), które może przekroczyć próg ustawiony dla rytmu muzycznego.
- **ZSTD < 0.025** (stabilny współczynnik przejść przez zero): To zazwyczaj główny winowajca fałszywych detekcji. Jeśli analizowany klip obejmie przedłużoną samogłoskę (np. "aaaa", "oooo") lub ciąg głosek dźwięcznych bez przerywających je spółgłosek szumiących ("sz", "cz", "s"), zmienność ZCR będzie drastycznie niska. Są to właśnie cechy charakterystyczne dla wywiadu czy rozmowy przez telefon.

Zmiana progów znacznie pogorszyłaby jakość klasyfiikacji nagrań muzycznych, dlatego zdecydowano się je zostawić. Uznano, iż lepiej jak kawałek mowy zostanie zaklasyfikowany jako muzyka, niż gdy fragment wyraźnej muzyki zostanie uznany jako fragment niemuzyczny.

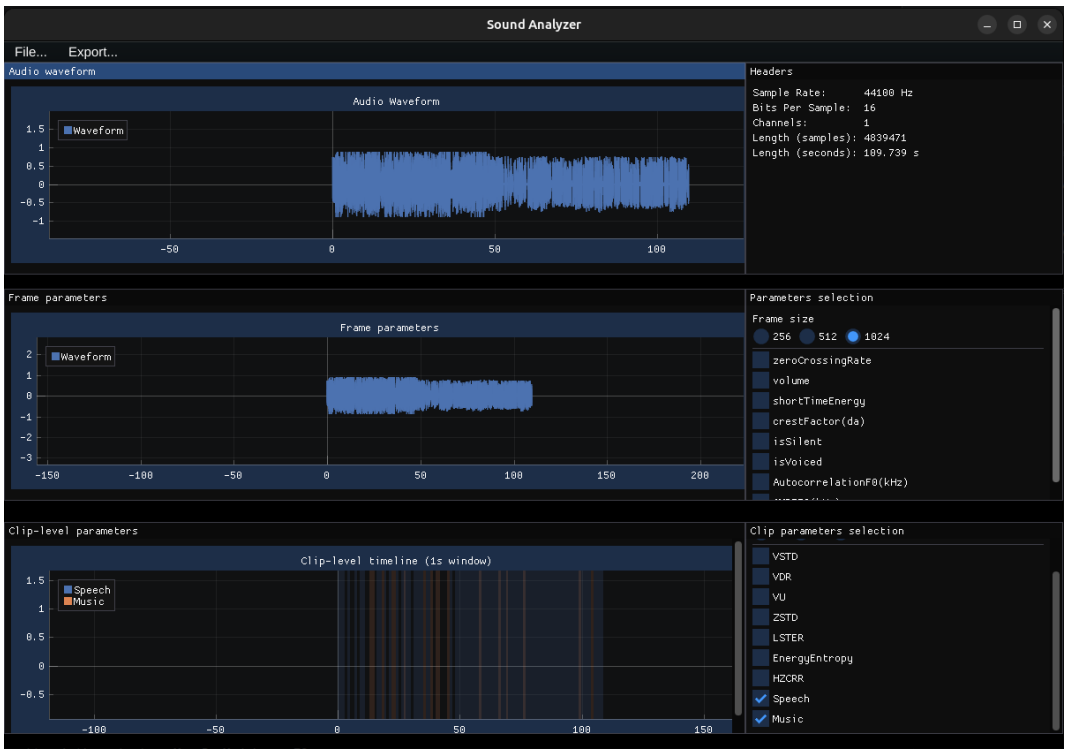

Rysunek 22. Detekcja mowy/muzyki na dźwięku rozmowy nałożonym na muzykę klasyczną

Na rysunku 22 jest analizowane audio, na którym jest nałożona rozmowa na muzykę klasyczną. Widać na wykresie częstotliwości charakterystyczny moment około 50 sekundy gdy następuje zmiana, w tamtym momencie kończy się muzyka i słychać samą rozmowę. Program całkiem dobrze sobie poradził z klasyfikacją jednak niestety problematyczne dla niego jest wykrycie jednoczesnej mowy oraz muzyki.

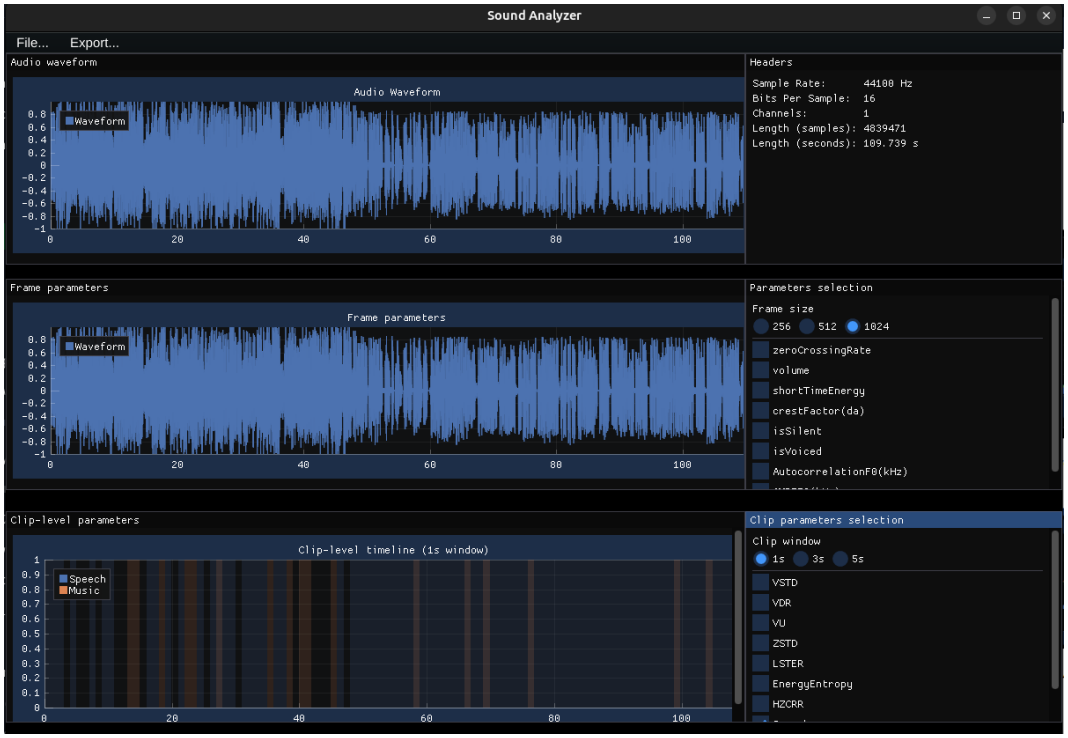

Rysunek 23. Detekcja mowy/muzyki w oknie o długości clipu 1s

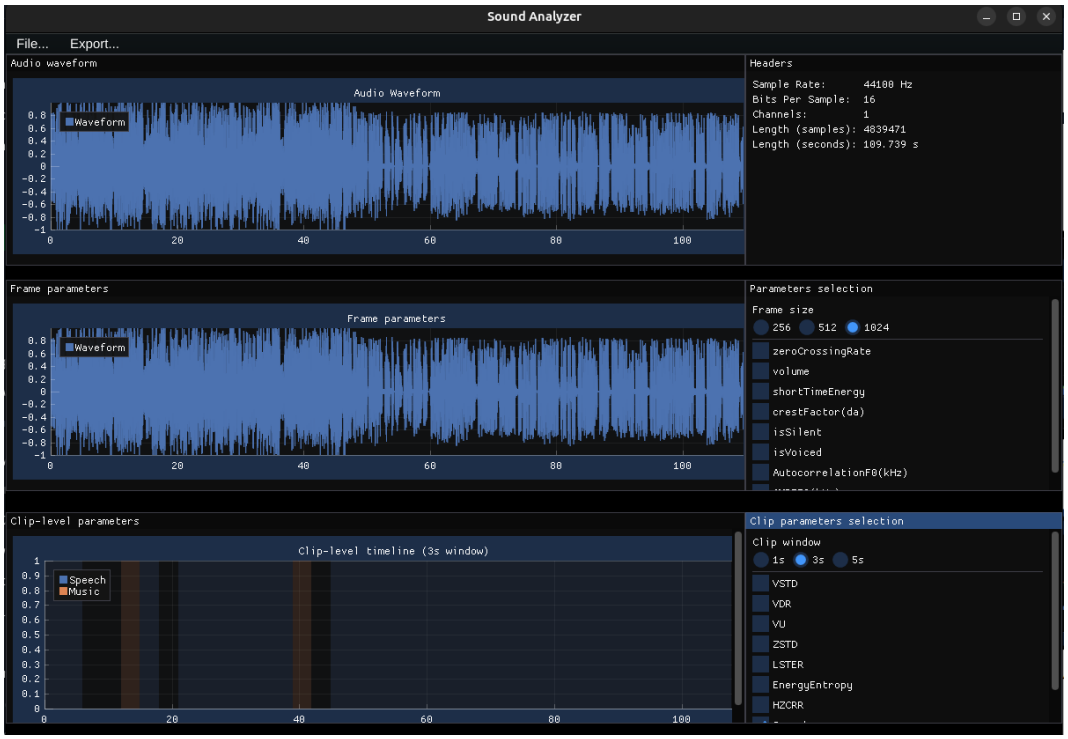

Rysunek 24. Detekcja mowy/muzyki w oknie o długości clipu 3s

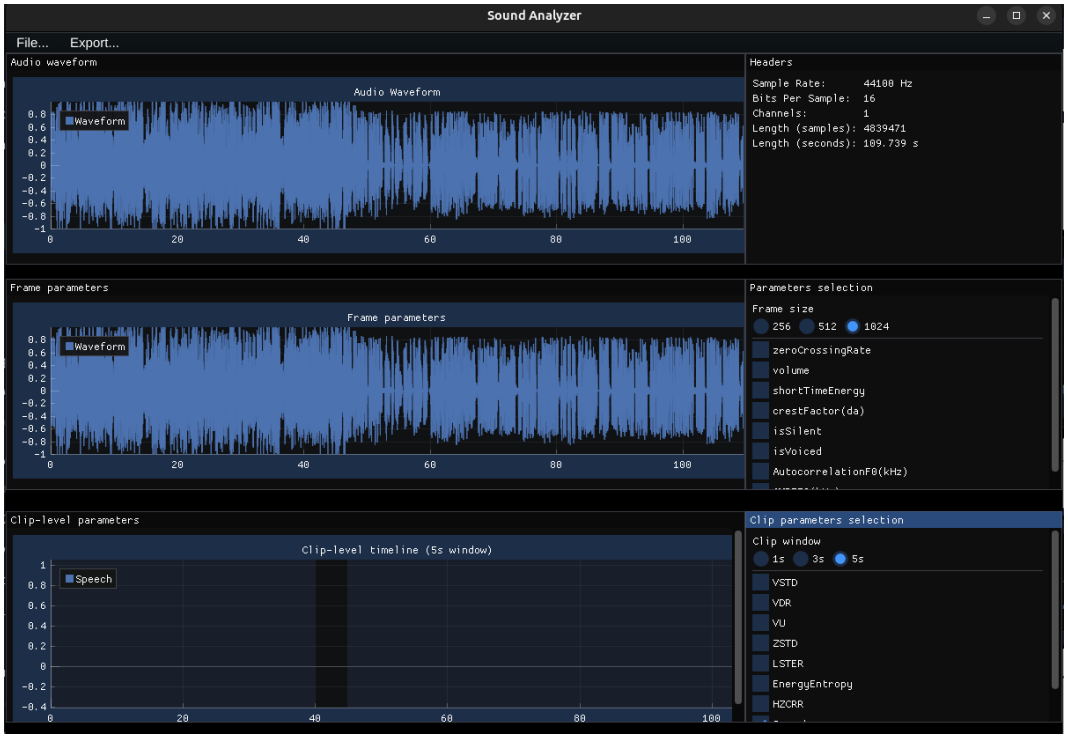

Rysunek 25. Detekcja mowy/muzyki w oknie o długości clipu 5s

Na Rysunkach 23–25 przedstawiono wpływ długości klipu na działanie klasyfikatora mowa/muzyka. Dla klipu o długości 1 s decyzje klasyfikacyjne zmieniają się często i są bardzo czułe na lokalne fluktuacje sygnału. Dzięki temu możliwe jest dokładniejsze wskazywanie krótkich fragmentów, jednak okupione jest to mniejszą stabilnością wyniku oraz większą liczbą pojedynczych, krótkotrwałych detekcji.

Dla klipu o długości 3 s klasyfikacja staje się wyraźnie bardziej stabilna. Krótkie, przypadkowe zmiany parametrów są częściowo wygładzane, a jednocześnie nadal zachowana zostaje stosunkowo dobra rozdzielczość czasowa. W badanym przykładzie taki rozmiar okna daje najbardziej zrównoważony wynik.

Dla klipu o długości 5 s wynik jest jeszcze bardziej wygładzony, ale jednocześnie klasyfikator traci czułość na krótsze zmiany charakteru sygnału. Decyzje pojawiają się rzadziej i obejmują dłuższe fragmenty czasu, przez co granice pomiędzy mową a muzyką są lokalizowane mniej precyzyjnie.

Przeprowadzony eksperyment potwierdza, że długość klipu ma istotny wpływ na zachowanie klasyfikatora. Krótsze okna zwiększają czułość na lokalne zmiany, natomiast dłuższe poprawiają stabilność kosztem dokładności czasowej. W analizowanym przypadku najbardziej praktycznym kompromisem okazało się okno 3-sekundowe.

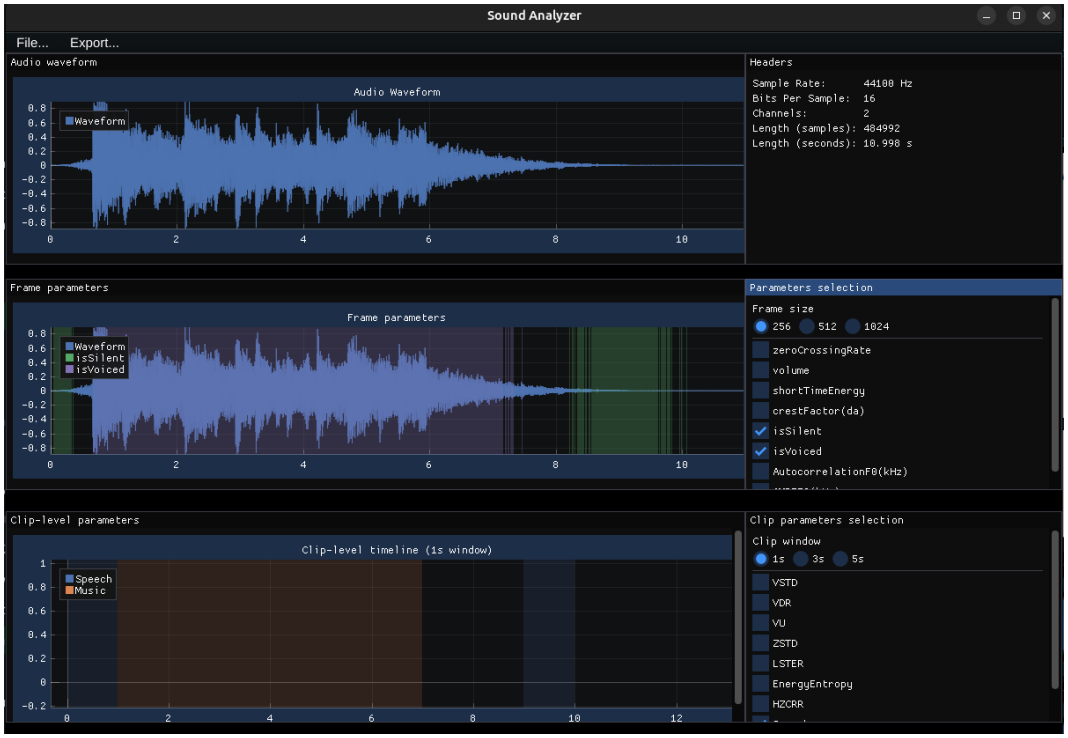

Rysunek 26. Detekcja mowy/muzyki, ciszy oraz fragmentów dźwięcznych w oknie o długości ramki 256

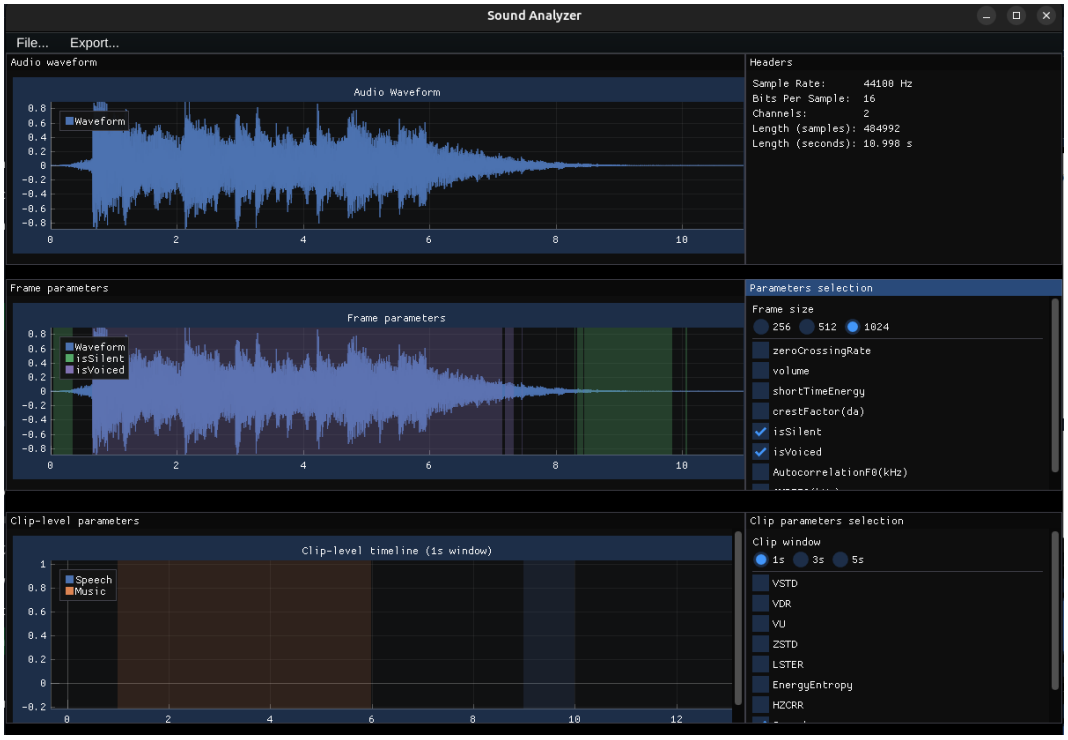

Rysunek 27. Detekcja mowy/muzyki, ciszy oraz fragmentów dźwięcznych w oknie o długości ramki 1024

Na Rysunkach 26, 27 przedstawiono wyniki analizy nagrania gry na pianinie dla dwóch różnych długości ramki. Zgodnie z oczekiwaniami zasadnicza część sygnału została sklasyfikowana jako dźwięczna, co odpowiada charakterowi dźwięku instrumentu muzycznego o

wyraźnej energii i uporządkowanej strukturze. Jednocześnie na początku oraz na końcu nagrania poprawnie wykryto fragmenty ciszy, co jest zgodne z rzeczywistym przebiegiem sygnału widocznym na waveformie.

Dodatkowo klasyfikacja na poziomie klipu oznacza analizowany fragment głównie jako muzykę, co również należy uznać za wynik prawidłowy. Potwierdza to, że zastosowany zestaw parametrów ramkowych i klipowych pozwala poprawnie opisywać nagrania instrumentalne.

Porównanie wyników dla długości ramki równej 256 oraz 1024 próbek pokazuje wpływ rozmiaru ramki na charakter analizy. Dla krótszej ramki (256) detekcja jest bardziej szczegółowa i czuła na lokalne zmiany sygnału, przez co granice między ciszą a aktywnością dźwiękową są wyznaczane z większą dokładnością czasową. Jednocześnie wynik jest bardziej podatny na krótkotrwałe fluktuacje. Z kolei dla dłuższej ramki (1024) przebiegi stają się bardziej wygładzone i stabilne, jednak maleje dokładność czasowa detekcji, a granice zmian są mniej precyzyjne.

Otrzymane wyniki potwierdzają więc typowy kompromis związany z doborem długości ramki: mniejsze ramki zapewniają lepszą rozdzielczość czasową, natomiast większe dają bardziej stabilne i uśrednione wyniki analizy.

Warto zwrócić uwagę, że błędnie klasyfikuje ostatnią sekundę nagrania jako mowę zarówno dla długości ramki 256 jak i 1024. Dodatkowo dla długości ramki 256 jako mowę oznaczono też błędnie pierwszą sekundę nagrania. Może to wynikać z faktu, że w początkowym i końcowym fragmencie nagrania sygnał ma mniejszą energię i mniej stabilny charakter, przez co wartości parametrów klipowych chwilowo upodabniają się do tych obserwowanych dla mowy. Pokazuje to, że klasyfikator muzyka/mowa jest wrażliwy na fragmenty przejściowe oraz na części nagrania o słabszej, zanikającej strukturze dźwięku.

4 Wnioski

4.1 Napotkane problemy

Najważniejszy problem dotyczył doboru progów decyzyjnych w detekcji ciszy. W testach potwierdzono, że dla sygnału znormalizowanego (o porównywalnym poziomie amplitudy między nagraniami) stałe progi dla cech takich jak Volume i ZCR dają przewidywalne i powtarzalne wyniki. Dla sygnału nieznormalizowanego te same progi tracą skuteczność, ponieważ różnice poziomu głośności między nagraniami przesuwają wartości cech i prowadzą do błędnych decyzji. Podobne problemy napotkaliśmy podczas doboru pozostałych progów.

4.2 Ocena działania metod

Zastosowane metody spełniły cel projektu: aplikacja umożliwia przejście od wczytania nagrania, przez podgląd przebiegu czasowego, po analizę cech i eksport wyników. Parametry liczone ramkowo i klipowo dają użyteczny opis zmian sygnału w czasie, a interfejs pozwala szybko porównywać ich przebiegi.

Ograniczenia są najbardziej widoczne przy detekcji ciszy w nagraniach zawierających

ambient lub stałe tło akustyczne (np. szum pomieszczenia, wentylację, dźwięki ulicy). W takich fragmentach sygnał rzadko osiąga poziom odpowiadający rzeczywistej ciszy, dlatego metoda progowa często nie oznacza ich jako ciszy, mimo że użytkownik odbiera je jako brak istotnej treści. Oznacza to, że obecna detekcja ciszy jest skuteczniejsza dla ciszy technicznej niż dla tzw. ciszy percepcyjnej.

4.3 Wpływ parametrów

Parametrów analizy nie można dobierać całkowicie dowolnie. Długość ramki wpływa na kompromis pomiędzy rozdzielczością czasową a stabilnością cech, natomiast długość klipu wpływa na stopień uśrednienia i czytelność trendów globalnych. Krótsze ramki lepiej lokalizują szybkie zmiany, ale są bardziej podatne na zakłócenia; dłuższe ramki stabilizują wyniki kosztem precyzji czasowej.

Kluczowy wpływ na działanie progów ma skala amplitudy wejściowej. W praktyce oznacza to, że dla danych znormalizowanych możliwe jest stosowanie jednego zestawu progów, natomiast dla danych nieznormalizowanych potrzebna jest adaptacja progów do konkretnego nagrania lub wcześniejsza normalizacja sygnału. Bez tego detekcja ciszy i klasyfikacja ramek stają się niestabilne między plikami.

4.4 Możliwe usprawnienia

Najbardziej uzasadnionym kierunkiem rozwoju jest wprowadzenie automatycznej normalizacji wejścia lub progów adaptacyjnych wyznaczanych na podstawie statystyk bieżącego nagrania. Takie podejście zwiększyłoby powtarzalność wyników bez konieczności ręcznego strojenia parametrów dla każdego pliku.

Drugim usprawnieniem powinno być rozszerzenie detekcji ciszy o analizę tła akustycznego (ambientu), np. przez estymację poziomu szumu tła i dynamiczne oddzielanie ciszy technicznej od fragmentów niskoenergetycznych.

5 Podsumowanie

Przeprowadzone eksperymenty potwierdziły, że cechy sygnału audio w dziedzinie czasu mogą być skutecznie wykorzystywane do podstawowej analizy nagrań, detekcji ciszy oraz prostej klasyfikacji fragmentów mowy i muzyki. Najlepsze wyniki uzyskano dla nagrań o ustabilizowanym poziomie amplitudy i wyraźnej strukturze sygnału. Otrzymane rezultaty pokazują jednak, że metody progowe mają ograniczoną odporność na szum tła, różnice poziomu nagrań oraz przypadki mieszane, co wskazuje na potrzebę dalszego rozwoju algorytmów